

UNIVERSIDAD PERUANA DE  
CIENCIAS APLICADAS  
FACULTAD DE INGENIERÍA  
COMPUTER SCIENCE PROFESSIONAL PROGRAM

---

Curso:

**1ACC0221-2610 — Big Data**

Sección: 18517

**Smart Kitchen Intelligence:  
Recomendador basado en Contenido,  
Filtrado  
Colaborativo y Modelo Híbrido  
Anti-Desperdicio**

**Informe Técnico — Hito 4 (Semana 11)**

*Recomendadores basados en contenido, filtrado  
colaborativo implícito (ALS) y recomendación mixta*

**Autores**

Melgar Puertas, José Guillermo    u202111660

Reyna Alvarado, Gabriel Alonso    u202126097

**Profesor**

Alarcon Delgado, Carlos Adrian

Lima, junio de 2026

# Índice general

|           |                                                                         |           |
|-----------|-------------------------------------------------------------------------|-----------|
| <b>1</b>  | <b>Introducción y Marco del Hito 4</b>                                  | <b>2</b>  |
| 1.1       | Tipo de proyecto y posición en el curso . . . . .                       | 2         |
| 1.2       | Ethics and Access Note . . . . .                                        | 3         |
| <b>2</b>  | <b>Datos y Artefactos Reutilizados</b>                                  | <b>3</b>  |
| <b>3</b>  | <b>Recomendador Basado en Contenido</b>                                 | <b>4</b>  |
| 3.1       | Definición de la representación híbrida del producto . . . . .          | 4         |
| 3.2       | Formulación matemática de TF-IDF . . . . .                              | 4         |
| 3.3       | Perfil del household y scoring . . . . .                                | 5         |
| 3.4       | Continuidad e Intervalo: corrección de la suposición de ortogonalidad . | 6         |
| <b>4</b>  | <b>Construcción de la Matriz R</b>                                      | <b>6</b>  |
| 4.1       | Unidad de las filas: sesiones, no households . . . . .                  | 6         |
| 4.2       | Encodings probados . . . . .                                            | 7         |
| 4.3       | Normalizaciones aplicadas . . . . .                                     | 8         |
| <b>5</b>  | <b>Filtrado Colaborativo</b>                                            | <b>9</b>  |
| 5.1       | Similitud ítem-ítem (Semana 10) . . . . .                               | 9         |
| 5.2       | ALS implícito (Semana 10) y lambda iteration . . . . .                  | 9         |
| <b>6</b>  | <b>Estrategias de Cold-Start</b>                                        | <b>11</b> |
| 6.1       | Sesión cold . . . . .                                                   | 11        |
| 6.2       | Producto cold . . . . .                                                 | 12        |
| <b>7</b>  | <b>Recomendador Híbrido (Mixed Recommendation)</b>                      | <b>12</b> |
| 7.1       | Ablación de pesos . . . . .                                             | 13        |
| <b>8</b>  | <b>Protocolo de Evaluación Offline Consolidado</b>                      | <b>14</b> |
| 8.1       | Definición del candidate pool . . . . .                                 | 14        |
| 8.2       | Protocolo común y Defensa contra el Data Leakage . . . . .              | 14        |
| 8.3       | Comparación baseline vs sistema fuerte . . . . .                        | 15        |
| 8.4       | Data alignment del híbrido . . . . .                                    | 17        |
| <b>9</b>  | <b>Análisis de Strong y Failure Cases</b>                               | <b>18</b> |
| 9.1       | Strong cases ( $\geq 2$ hits en top-5) . . . . .                        | 18        |
| 9.2       | Failure cases (0 hits en top-5) . . . . .                               | 19        |
| <b>10</b> | <b>Conclusiones</b>                                                     | <b>19</b> |

# 1 Introducción y Marco del Hito 4

El presente informe documenta el **Hito 4** del proyecto *Smart Kitchen Intelligence* (SKI), correspondiente al contenido de las Semanas 9 y 10 del curso y a la entrega de la Semana 11. El hito construye, sobre el dataset consolidado en el Hito 1 y las representaciones del Hito 2, un **motor de recomendación de tres capas**: (i) basado en contenido con TF-IDF sobre el catálogo, (ii) filtrado colaborativo implícito mediante factorización ALS con barrido de regularización ( $\lambda$ ), y (iii) un recomendador híbrido que integra ambas señales con un componente *anti-desperdicio* derivado de la proximidad de vencimiento.

El informe se estructura en torno a las seis preguntas técnicas planteadas explícitamente por el profesor para la sustentación de la Semana 11:

1. **Construcción de R**: qué unidad usamos como filas, qué encodings probamos.
2. **Normalización**: qué transformación aplicamos y por qué.
3. **Lambda iteration**: cuál estrategia usamos para regularizar ALS.
4. **Justificación**: por qué esa estrategia es la mejor para SKI.
5. **Datos que respaldan**: métricas empíricas que sostienen cada decisión.
6. **Comprensión de TF-IDF**: qué hace formalmente y por qué es adecuado.

Cada sección del informe responde a una o varias de estas preguntas de manera directa, con la métrica observada al lado de cada afirmación cuantitativa.

## 1.1 Tipo de proyecto y posición en el curso

Según la taxonomía declarada en el *Semester Group Assignment Brief*, el sistema construido en este hito es un **recommendation system** sobre la unidad *sesión de despensa*, no una tarea pura de ranking ni de predicción supervisada. Concretamente:

- **Recomendación**: dado un perfil (household) o un seed parcial (sesión cold), el sistema devuelve un top- $N$  de productos candidatos. Esta es la operación primaria.
- **Segmentación que alimenta el ranking**: los 38 clusters del Hito 3 actúan como capa latente que valida la coherencia interna, pero el ranking no se condiciona sobre el cluster ID; se condiciona sobre el perfil completo del household.
- **No es predicción supervisada**: no hay etiquetas binarias de “compra” vs “no compra” a predecir; el modelo aprende a re-ranear el catálogo a partir de interacciones positivas implícitas.

## 1.2 Ethics and Access Note

**Origen de los datos.** El catálogo de productos proviene de la API pública [OpenFoodFacts](#) (licencia ODbL); los patrones de comportamiento usados para parametrizar el simulador derivan del dataset público *Instacart Online Grocery Shopping* (uso académico permitido). La capa de eventos de inventario (25,444 registros) es **sintética**, generada por `src/simulation.py` sobre la base de las distribuciones de Instacart; no contiene datos personales de usuarios reales.

**Por qué se permite usarlos.** Ambas fuentes son públicas y su uso académico está autorizado por sus licencias. La simulación elimina cualquier identificador personal por construcción: los `household_id` son enteros 0–9 generados por el script.

**Riesgos de datos personales y mitigaciones.** En el dataset entregado no hay PII (nombres, direcciones, emails). Si en una extensión futura el sistema ingiriera historiales reales de hogares, se aplicarían: (i) hashing de identificadores con salt fijo en pipeline, (ii) agregación por sesión antes de persistir, (iii) eliminación de `timestamp` exacto en favor de bin temporal de 15 minutos. Para el Hito 4 estas medidas no son necesarias porque la capa de interacción es sintética.

**Limitación honesta.** Al ser sintético, el dataset hereda los sesgos del simulador (distribución uniforme entre households, ventanas operacionales fijas). Las métricas obtenidas son por tanto un *piso* para la calidad del sistema sobre datos reales, no un techo.

## 2 Datos y Artefactos Reutilizados

El motor se construye sobre el dataset `data/processed/inventory_v1.csv` producido en el Hito 1, que contiene **25,444 eventos** de inventario distribuidos en **10 households** y **50 productos únicos** a lo largo de 13 semanas. Cada evento registra `event_type` (IN/OUT), `quantity`, `timestamp`, `expiry_date`, `nutriscore` y atributos categóricos del producto.

El cluster de comportamiento entregado en el Hito 3 (DBSCAN  $\varepsilon = 2.7$ , **Silhouette** = 0.6549) actúa como capa latente de segmentación para validar consistencia, pero no se usa como entrada directa del recomendador: la decisión es deliberada porque el clustering opera sobre eventos individuales mientras que el filtrado colaborativo opera sobre sesiones de despensa.

### 3 Recomendador Basado en Contenido

#### 3.1 Definición de la representación híbrida del producto

En el ejemplo *Pachamix Lyrics* del curso, cada documento es la letra de una canción. En SKI no existe texto libre asociado al producto, por lo que cada ítem se representa con un **vector híbrido** de dos bloques: un bloque *textual* TF-IDF construido sobre los atributos genuinamente nominales del producto, y un bloque *numérico* con las variables físicas que poseen orden e intervalo (macronutrientes y nutriscore):

```

1 # Bloque textual (solo atributos nominales, sin orden interno)
2 doc = product_name + " " +
3     f"category_{category} class_{classification}"
4 X_text = TfidfVectorizer().fit_transform(docs)           # filas L2
5
6 # Bloque numerico (variables continuas/ordinales escaladas)
7 num = [calories_100g, proteins_100g, carbs_100g, nutri_ord] # nutri A->E
8     = 0..4
9 X_num = MinMaxScaler().fit_transform(num) * numeric_weight # una dim
10     por variable
11
12 # Concatenacion y L2-normalizacion final (cosine == dot product)
13 X = l2_normalize( hstack([X_text, X_num]) )

```

A diferencia de la versión inicial, los macronutrientes **ya no se discretizan** en tokens `cal_low/cal_mid/cal_high`: cada macro y el nutriscore ocupan **una sola dimensión numérica ordenada**, de modo que la distancia respeta el intervalo físico real (ver Sección 3.4). El catálogo final contiene 50 ítems con un espacio de **82 dimensiones** (**78 tokens** textuales + **4 dimensiones** numéricas), con peso relativo del bloque numérico `numeric_weight = 0.5`.

#### 3.2 Formulación matemática de TF-IDF

Para defender el método ante una pregunta directa del profesor, se explicita la formulación completa:

$$\text{tf}(t, d) = \frac{f_{t,d}}{\sum_{t'} f_{t',d}} \quad \text{o sublineal: } 1 + \log f_{t,d} \quad (1)$$

$$\text{idf}(t) = \log \left( \frac{1 + N}{1 + \text{df}(t)} \right) + 1 \quad (2)$$

$$\text{tfidf}(t, d) = \text{tf}(t, d) \cdot \text{idf}(t) \quad (3)$$

$$\mathbf{x}_d = \frac{\text{tfidf}(\cdot, d)}{\|\text{tfidf}(\cdot, d)\|_2} \quad (\text{normalización L2}) \quad (4)$$

donde  $N$  es el número de documentos y  $\text{df}(t)$  el número de documentos donde aparece el término  $t$ . La normalización L2 implica que el dot product entre dos vectores coincide con la **similitud coseno**. La función IDF penaliza tokens ubicuos (mayor  $\text{df}$ , menor IDF) y premia tokens discriminantes. Tras eliminar los tokens de macros discretizadas, los tokens textuales con menor IDF observados son “**class\_purchase**” (1.13), “**category\_4**” (1.22) y “**organic**” (1.44); los más informativos son nombres específicos como “**cilantro**”, “**zucchini**” y “**tomato**” con  $\text{IDF} \approx 4.24$  (Figura 1). Las cuatro dimensiones numéricas (macros + nutriscore) se añaden tras este bloque y no participan del cálculo de IDF.




Figura 1: Distribución de IDF en el catálogo SKI. Izquierda: tokens más comunes (penalizados). Derecha: tokens más raros (premiados).

### 3.3 Perfil del household y scoring

El perfil del household  $u$  se construye como promedio ponderado de los vectores TF-IDF de los productos que ha consumido, con peso  $w_p = \text{freq}(p) / \sum_q \text{freq}(q)$ :

$$\mathbf{p}_u = \sum_{p \in \text{OUT}_u} w_p \cdot \mathbf{x}_p$$

Esto es exactamente la operación *group by household* sobre los vectores del catálogo. La recomendación top- $N$  se obtiene rankeando por similitud coseno  $\text{score}(u, p) = \mathbf{p}_u \cdot \mathbf{x}_p$ , excluyendo productos ya consumidos visibles y aplicando un **group by category** (máximo 1 por categoría dentro del top) para evitar saturar la salida con un mismo tipo de producto.

**Validación cualitativa (hold-out 20%).** Para el household 0, ocultando aleatoriamente 10/50 productos de su historial, las recomendaciones del top resultan todas aciertos sobre el conjunto oculto (Parsley, Half&Half, Hummus, Spring Water), lo que ilustra que el perfil de contenido híbrido captura preferencias incluso sin observar historial colaborativo.

### 3.4 Continuidad e Intervalo: corrección de la suposición de ortogonalidad

La primera versión de esta capa discretizaba las variables continuas de la API de la USDA en tokens (`cal_low`, `cal_mid`, `cal_high`, etc.). Al transformar los macronutrientes en tokens de texto independientes dentro del pseudo-documento, la similitud coseno subyacente los trataba como dimensiones estrictamente **ortogonales**: el modelo asumía que la distancia entre `cal_low` y `cal_mid` era idéntica a la distancia entre `cal_low` y `cal_high`, perdiendo la noción de *intervalo* y *orden* de las variables físicas nutricionales.

**Corrección aplicada.** En esta versión las macronutricionales y el nutriscore se retiran del bloque de tokens y se reincorporan como **ejes numéricos ordenados**. Cada variable física (calories, proteins, carbs) ocupa una única dimensión escalada a  $[0, 1]$  con `MinMaxScaler`, y el nutriscore se codifica como un eje ordinal  $A \rightarrow E \equiv \{0, 1, 2, 3, 4\}$ . El vector de cada producto es entonces

$$\mathbf{x}_p = \text{L2}\left(\left[ \underbrace{\mathbf{x}_p^{\text{TF-IDF}}}_{\text{texto nominal}} \parallel \underbrace{\beta \cdot \phi_{\text{MinMax}}(\text{macros}_p, \text{nutri}_p)}_{\text{bloque numerico, } \beta=0.5} \right] \right),$$

donde  $\parallel$  denota concatenación y  $\text{L2}(\cdot)$  la normalización por fila final que mantiene la equivalencia  $\cosine = \text{dot product}$ . Con esta representación, la distancia en la dimensión de calorías es proporcional a la diferencia real de la variable:  $|\text{cal}=180 - \text{cal}=190| \ll |\text{cal}=50 - \text{cal}=900|$ , recuperándose orden e intervalo que la tokenización había destruido. El peso  $\beta$  regula la influencia del bloque numérico frente al textual sin que ninguno domine. El esquema es compatible con futuras extensiones (*target encoding* no lineal o recomendador de dos torres) sin reintroducir la ortogonalidad.

## 4 Construcción de la Matriz R

### 4.1 Unidad de las filas: sesiones, no households

El ejemplo del curso usa *playlists* como filas. La traducción ingenua a SKI (households como filas) produce una matriz  $10 \times 50$  **con densidad 100%**: como cada household compró cada producto al menos una vez en 13 semanas, el dot product entre columnas se reduce a la popularidad global y el filtrado colaborativo se degenera. Para evitarlo, definimos dos unidades de *playlist* alineadas con las ventanas operacionales declaradas en `proposal.md`:

- **Restock Window** (`R_restock_*`): grupos de eventos IN dentro de una ventana de 60 minutos por household. Equivalen a una sesión de compra / abastecimiento. Producen **1,177 sesiones** con un promedio de **8.7 productos por sesión**.



- **Kitchen Session** (`R_kitchen_*`): grupos de eventos OUT dentro de 15 minutos por household. Equivalen a una sesión de preparación. Producen **8,075 sesiones** con 1.7 productos en promedio.

## 4.2 Encodings probados

Sobre la unidad de sesión se construyen cuatro encodings de R alineados con la recomendación explícita del profesor (Semana 10):

1. **Binaria:**  $R_{ui} = \mathbb{1}\{\text{producto } i \in \text{sesión } u\}$ .
2. **Conteo:**  $R_{ui} = \text{número de eventos del producto } i \text{ en la sesión } u$ .
3. **Cantidad:**  $R_{ui} = \sum \text{quantity del producto } i \text{ en la sesión } u$ .
4. **Frecuencia normalizada:**  $R_{ui} = \text{conteo} / \text{tamaño de sesión (stochastic por fila)}$ .

Cuadro 1: Comparativa de variantes de R (sparsity = 1– densidad).

| Matriz                         | Shape            | nnz    | Densidad |
|--------------------------------|------------------|--------|----------|
| <code>R_restock_bin</code>     | $1177 \times 50$ | 10,260 | 0.1743   |
| <code>R_restock_count</code>   | $1177 \times 50$ | 10,260 | 0.1743   |
| <code>R_restock_qty</code>     | $1177 \times 50$ | 10,260 | 0.1743   |
| <code>R_restock_freq</code>    | $1177 \times 50$ | 10,260 | 0.1743   |
| <code>R_kitchen_bin</code>     | $8075 \times 50$ | 13,707 | 0.0339   |
| <code>R_kitchen_count</code>   | $8075 \times 50$ | 13,707 | 0.0339   |
| <code>R_household_bin</code>   | $10 \times 50$   | 500    | 1.0000   |
| <code>R_household_count</code> | $10 \times 50$   | 500    | 1.0000   |




Figura 2: Densidad de cada variante de R. El caso `R_household_*` confirma la degeneración (densidad 1.0); los encodings sobre sesiones recuperan sparsity realista.

La matriz seleccionada como base del CF es `R_restock_bin`: la sparsity es suficiente para que el dot product entre columnas tenga significado (co-ocurrencia entre productos en sesiones de despensa), y la interpretación binaria evita que el conteo de eventos infla artificialmente la señal cuando el simulador genera múltiples registros por producto.

### 4.3 Normalizaciones aplicadas

Sobre `R_restock_count` se evalúan cinco normalizaciones (Figura 3) cuya justificación se resume en la Tabla 2:

Cuadro 2: Normalizaciones sobre R y caso de uso.

| Normalización                | Justificación                                                                                                                                                              |
|------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <code>raw</code>             | Línea base; preserva escala original.                                                                                                                                      |
| <code>row_mean_center</code> | Resta media por fila, corrige el sesgo de sesiones más activas. Permite distinguir productos sobre-representados vs sub-representados <i>respecto a la propia sesión</i> . |
| <code>log1p</code>           | Comprime distribuciones largas en <code>count/qty</code> ; convierte una preferencia $5\times$ en algo cercano a $2\times$ en log-escala.                                  |
| <code>tfidf_R</code>         | Aplica IDF <i>sobre productos</i> : penaliza ítems ubicuos en sesiones (ej. leche en casi todas las compras) y resalta discriminantes.                                     |
| <code>l2_row</code>          | Normaliza filas a norma 1. Hace que el dot product entre filas sea cosine sim, invariante al tamaño de la sesión.                                                          |




Figura 3: Distribución de los valores no-cero de R por normalización.

**Decisión de normalización.** Para **similitud ítem-ítem** se adopta **l2\_row**, porque convierte el dot product entre columnas en cosine sim invariante al tamaño de la sesión. Para **ALS implícito** se adopta **tfidf\_R**: en SKI un puñado de productos básicos (manzana, leche, plátano) aparecen en casi todas las sesiones de restock; sin TF-IDF, ALS los aprende como factores latentes dominantes y desplaza a los productos más informativos. El log1p subyacente, además, evita que sesiones muy activas saturen la función de pérdida.

## 5 Filtrado Colaborativo

### 5.1 Similitud ítem-ítem (Semana 10)

Para una interpretación inmediata se calcula la similitud ítem-ítem por dot product directo y por cosine similarity sobre **R\_restock\_bin**:

$$\text{dot}(i, j) = \sum_u R_{u,i} \cdot R_{u,j}, \quad \cos(i, j) = \frac{\mathbf{r}_i \cdot \mathbf{r}_j}{\|\mathbf{r}_i\| \cdot \|\mathbf{r}_j\|}$$

La interpretación es directa:  $\text{dot}(i, j)$  es **el número de sesiones de despensa donde los productos  $i$  y  $j$  co-ocurren**, y  $\cos(i, j)$  normaliza por la popularidad individual. Ejemplo:  $\text{dot}(0, 1) = 40$  (40 sesiones),  $\cos(0, 1) = 0.2005$ .

Sobre estas similitudes se comparan dos enfoques:

- **Contenido (TF-IDF del catálogo):** similitud entre productos por descripción.
- **Colaborativo (ítem-ítem sobre R):** similitud por comportamiento conjunto.

Ambas señales coexisten en el recomendador híbrido (Sección 7).

### 5.2 ALS implícito (Semana 10) y lambda iteration

Para CF latente se implementa ALS implícito en la formulación de Hu, Koren y Volinsky [1]. La función objetivo es:

$$\min_{X,Y} \sum_{u,i} c_{ui} (p_{ui} - \mathbf{x}_u^\top \mathbf{y}_i)^2 + \lambda \left( \sum_u \|\mathbf{x}_u\|^2 + \sum_i \|\mathbf{y}_i\|^2 \right) \quad (5)$$

donde  $p_{ui} = \mathbb{I}\{R_{ui} > 0\}$  es la preferencia binaria y  $c_{ui} = 1 + \alpha R_{ui}$  es la confianza. La iteración alterna entre actualizar  $X$  con  $Y$  fijo y viceversa, resolviendo en cada paso un sistema lineal cerrado:

$$\mathbf{x}_u = (Y^\top C^u Y + \lambda I)^{-1} Y^\top C^u \mathbf{p}_u$$

**Estrategia de lambda iteration.** Se barre  $\lambda \in \{0.001, 0.01, 0.1, 0.5, 1, 5, 10\}$  con  $\text{factors} = 16$ ,  $\alpha = 20$ , 8 iteraciones, sobre `R_restock_tfidf_R`. La métrica es **precision@5** y **recall@5** medidas sobre un hold-out aleatorio del 20% de las interacciones. Los resultados se muestran en la Tabla 3 y la Figura 4.

Cuadro 3: Resultados del barrido de  $\lambda$  en ALS implícito.

| $\lambda$    | precision@5   | recall@5      |
|--------------|---------------|---------------|
| 0.001        | 0.0469        | 0.1031        |
| 0.010        | 0.0486        | 0.1066        |
| 0.100        | 0.0471        | 0.1091        |
| 0.500        | 0.0486        | 0.1139        |
| <b>1.000</b> | <b>0.0494</b> | <b>0.1163</b> |
| 5.000        | 0.0483        | 0.1135        |
| 10.000       | 0.0488        | 0.1150        |




Figura 4: Curvas precision@5 y recall@5 vs  $\lambda$ . El óptimo se encuentra en  $\lambda = 1.0$ .

**Decisión de  $\lambda$ .** Se selecciona  $\lambda = 1.0$  porque maximiza simultáneamente precision@5 y recall@5 en hold-out. La curva es *cóncava* en escala logarítmica, lo que es consistente

con la teoría:  $\lambda$  muy pequeño sobreajusta a la matriz observada (que es ruidosa por el simulador),  $\lambda$  muy grande aplasta los factores latentes hacia cero y converge a un score trivial. Esta elección es **respaldada por los datos del hold-out**, no por defecto: el contraste  $\lambda = 0.001$  vs  $\lambda = 1.0$  muestra un aumento del recall del 12.8%.

## 6 Estrategias de Cold-Start

Se distinguen dos escenarios de cold-start:

1. **Sesión cold**: una nueva sesión de despensa con 1–2 productos seed conocidos.
2. **Producto cold**: un producto que no aparece en R (recién introducido al catálogo).

### 6.1 Sesión cold

Se evalúan cuatro estrategias sobre el **universo completo de sesiones elegibles** (todas las sesiones con  $\geq$  seed+1 productos; ya no un submuestreo aleatorio de 400, para estandarizar el universo de prueba): *(i)* popularidad pura, *(ii)* **partial CF** (k-NN ítem-ítem promediado sobre los seeds), *(iii)* content-only (similitud coseno de contenido promediada sobre los seeds), y *(iv)* mixed (popularidad  $\alpha$  + contenido  $(1 - \alpha)$  con  $\alpha = 0.4$ ). El candidate pool es *idéntico* al de la evaluación global (Sección 8): catálogo completo de 50 productos menos los seeds conocidos.

Cuadro 4: Métricas por estrategia (sesión cold). Se reportan precision@5 cruda (1 y 2 seeds) y, para el caso de 1 seed, las métricas normalizadas nprec@5 = hits/ min( $k$ , |truth|) y map@5, comparables con la evaluación global.

| Estrategia        | prec@5 (1s)   | prec@5 (2s)   | nprec@5 (1s)  | MAP@5 (1s)    |
|-------------------|---------------|---------------|---------------|---------------|
| popularity        | 0.1725        | 0.1545        | 0.1767        | 0.0990        |
| <b>partial_cf</b> | <b>0.1941</b> | <b>0.1850</b> | <b>0.1976</b> | <b>0.1163</b> |
| content_only      | 0.1580        | 0.1395        | 0.1609        | 0.0835        |
| mixed             | 0.1638        | 0.1458        | 0.1680        | 0.0910        |




Figura 5: Comparativa de estrategias cold-start.

**Decisión.** Se elige **partial CF** porque supera a popularidad pura en +12.5% (1 seed) y +19.7% (2 seeds), y lidera también en las métricas normalizadas **npred@5** y **MAP@5**. *Los datos lo respaldan:* la mejora se mantiene al variar el número de seeds y al cambiar de métrica, lo que descarta que sea efecto del azar o del techo de **precision@5**.

## 6.2 Producto cold

Para un producto sin historial, content-only es la única estrategia viable. Se evalúa midiendo si los  $k = 5$  vecinos por contenido se encuentran entre los productos realmente co-ocurrentes en las sesiones donde el producto cold aparece. Resultado: **precision@5 = 0.80** promediado sobre los 50 productos. Es decir, 4 de cada 5 vecinos por contenido están entre los productos que, empíricamente, los hogares compran junto al producto cold.

## 7 Recomendador Híbrido (Mixed Recommendation)

La combinación final es lineal sobre puntajes normalizados a  $[0, 1]$ :

$$\text{score}(u, p) = w_C \cdot \tilde{s}_{\text{cont}} + w_F \cdot \tilde{s}_{\text{cf}} + w_E \cdot \tilde{s}_{\text{exp}} \quad (6)$$

con:

- $\tilde{s}_{\text{cont}}$ : cosine sim contra perfil TF-IDF del household.
- $\tilde{s}_{\text{cf}}$ :  $\mathbf{x}_u^\top \mathbf{y}_p$  con  $\mathbf{x}_u$  inferido por mínimos cuadrados sobre  $Y$  entrenado en ALS con  $\lambda = 1.0$ .

- $\tilde{s}_{\text{exp}}$ :  $1/(1+d)$  con  $d$  la mediana de días hasta vencimiento de las unidades vivas del producto en el inventario del household. **Componente diferencial de SKI:** empuja productos en riesgo de desperdicio.

## 7.1 Ablación de pesos

La Tabla 5 y la Figura 6 muestran precision@5 sobre 200 sesiones con la mitad oculta, para distintos pesos.

Cuadro 5: Ablación de pesos del recomendador híbrido.

| $w_C$       | $w_F$       | $w_E$       | precision@5   |
|-------------|-------------|-------------|---------------|
| 1.00        | 0.00        | 0.00        | 0.1000        |
| 0.00        | 1.00        | 0.00        | 0.1070        |
| 0.00        | 0.00        | 1.00        | 0.0950        |
| <b>0.50</b> | <b>0.50</b> | <b>0.00</b> | <b>0.1130</b> |
| 0.35        | 0.45        | 0.20        | 0.0870        |
| 0.25        | 0.45        | 0.30        | 0.1100        |




Figura 6: precision@5 por combinación de pesos.

**Lectura.** Sobre la métrica de *hit* (precision@5), la combinación que maximiza es  $w_C = w_F = 0.5, w_E = 0$ . Sin embargo, esta métrica *no captura el objetivo anti-desperdicio* del proyecto: penaliza al modelo por recomendar productos en riesgo de vencimiento que aún no han aparecido en la sesión observada. Para producción se adopta  $w_C = 0.35, w_F = 0.45, w_E = 0.20$  como compromiso: mantiene precision@5

dentro del 23% del óptimo y prioriza el consumo de productos perecederos, alineado con la pregunta del producto declarada en la propuesta del Hito 1.

## 8 Protocolo de Evaluación Offline Consolidado

Las secciones previas reportan métricas por experimento aislado (lambda sweep, cold-start, ablación de pesos). Esta sección consolida los cuatro sistemas evaluados bajo un único protocolo metodológico idéntico, cumpliendo estrictamente con lo exigido en la rúbrica oficial del curso (*Week 10 milestone: “one offline evaluation report — metrics, candidate-pool definition, comparison against baselines”*).

Adicionalmente, esta consolidación establece formalmente el encuadre operativo de la tarea predictiva, justificando el diseño del split de datos frente a las condiciones reales de producción en el entorno de la cocina inteligente.

### 8.1 Definición del candidate pool

Para una sesión de evaluación  $u$ , el conjunto de productos candidatos sobre el que el sistema calcula el score y genera el ranking top- $N$  se define matemáticamente como:

$$\mathcal{C}_u = \{\text{los 50 productos del catálogo}\} \setminus \{i : R_{u,i}^{\text{train}} > 0\}$$

es decir, el catálogo completo **menos** las interacciones que ya han sido observadas y registradas en la matriz de entrenamiento de esa sesión específica. La justificación de esta máscara estricta responde a un criterio de producto: en producción, SKI debe sugerir nuevos elementos para completar el reabastecimiento interactivo, por lo que el acierto no debe ser inflado artificialmente recomendando ítems que el usuario ya ha introducido en su canasta activa. La verificación final de existencias físicas concurrentes se delega a una capa de lógica de inventario posterior, no al motor de recomendación. El truth set equivale exclusivamente al conjunto de productos enmascarados de la sesión  $u$  en el set de hold-out.

### 8.2 Protocolo común y Defensa contra el Data Leakage

El pipeline analítico se rige por las siguientes especificaciones técnicas de control:

- **Unidad:** `R_restock_bin`, 1,177 sesiones operacionales  $\times$  50 productos únicos del catálogo.
- **Split y Task Framing:** 20% de las interacciones no-cero se enmascararon aleatoriamente utilizando una semilla fija 42.



- **Hold-out efectivo:** 2,094 interacciones ocultas distribuidas a lo largo de 968 sesiones válidas de evaluación.
- **Métricas:** precision@5, recall@5, nprec@5 (precisión normalizada por techo, = hits/ min( $k$ , |truth|)), MAP@5 y catalog coverage@5.
- **Implementación:** `src/evaluation.py`, orquestado como un script modular ejecutable de forma independiente de la memoria oculta de Jupyter.

**Defensa Teórica del Paradigma Cloze Task Style.** Ante la posible objeción analítica de que un enmascaramiento puramente aleatorio de celdas introduce un sesgo de *temporal/concurrent leakage* intra-sesión (donde el modelo usa elementos simultáneos de una ventana de 60 minutos para predecir el hold-out), el equipo define conceptualmente la tarea bajo el **Paradigma de Tarea de Completitud de Canasta Enmascarada** (*Masked Basket Completion Task / Cloze Task Style*).

El sistema SKI en este hito no está planteado como un predictor secuencial cronológico longitudinal de la próxima semana, sino como un asistente interactivo en tiempo real. Su objetivo es deducir, a partir de semillas parciales que el usuario escanea en su despensa en una ventana activa, qué otros productos de esa misma canasta latente le falta registrar. Al formularlo formalmente como una tarea de clausura estructural (análogo al enmascaramiento de tokens intermedios en modelos MLM de procesamiento de lenguaje), el split aleatorio ciego intra-sesión es metodológicamente el enfoque correcto para evaluar la capacidad de cross-selling y reconstrucción inmediata en producción.

### 8.3 Comparación baseline vs sistema fuerte

Cuadro 6: Evaluación consolidada de los cuatro sistemas sobre el mismo hold-out.

| Sistema                           | precision@5   | recall@5      | nprec@5       | MAP@5         | coverage@5    |
|-----------------------------------|---------------|---------------|---------------|---------------|---------------|
| popularity (baseline trivial)     | <b>0.0508</b> | 0.1167        | 0.1174        | 0.0539        | 0.2200        |
| content_tfidf (baseline content)  | 0.0450        | 0.1037        | 0.1039        | 0.0511        | 0.8400        |
| cf_als (stronger, $\lambda=1.0$ ) | 0.0467        | 0.1125        | 0.1131        | 0.0549        | <b>1.0000</b> |
| hybrid (stronger, mixed)          | 0.0494        | <b>0.1177</b> | <b>0.1181</b> | <b>0.0574</b> | <b>1.0000</b> |

**Lectura técnica y Efecto de Productos Ubicuos Estructurales.** La comparación honesta plasmada en la Tabla 6 muestra que el sistema de popularidad pura (baseline trivial) solo conserva una ventaja marginal en **precision@5** (0.0508 frente a 0.0494 del híbrido, una diferencia de apenas 0.0014). En el resto de métricas el modelo **híbrido domina**: lo supera en **recall@5** (0.1177 vs 0.1167), en **nprec@5** (0.1181 vs 0.1174) y en **MAP@5** (0.0574 vs 0.0539). El equipo determina que la pequeña ventaja residual de

la popularidad en **precision@5** no responde a una superioridad predictiva real, sino a una propiedad patológica del entorno sintético parametrizado, denominada **Sesgo de Consumo Basal**.

Debido al **Efecto de Productos Ubicuos Estructurales** inyectado por el simulador estocástico, un conjunto cerrado de productos básicos de alta rotación (v.g., leche, plátanos, manzanas) aparece de manera redundante en la gran mayoría de las canastas analizadas. En consecuencia, un recomendador ciego que apunte siempre a los elementos más vendidos atinará con alta frecuencia matemática en el hold-out. Sin embargo, este enfoque adolece de un colapso crítico en la diversidad del sistema, contrayendo el **coverage@5** a un magro 0.2200 (22%) y restringiendo las sugerencias a solo 11 de los 50 productos disponibles. Por el contrario, la factorización matricial de ALS y el modelo híbrido rompen este sesgo estructural, forzando la salida y el descubrimiento de todo el inventario al alcanzar un **100% de catalog coverage** y, además, alcanzando el mejor MAP@5 del estudio (0.0574 en el híbrido), lo que demuestra que ordenan de mejor manera los aciertos cualitativos dentro del corte del top-5.

**Decisión de Sistema de Producción y Penalización por Trivialidad.** En el contexto de *Smart Kitchen Intelligence*, los objetivos centrales de negocio son el descubrimiento de inventario (sugerir e incentivar la rotación de productos que el household no acostumbra comprar por mero hábito repetitivo) y la mitigación del desperdicio de unidades perecederas vivas. Bajo estas directrices operacionales, el baseline de popularidad pura es completamente inadmisibile para producción masiva, ya que anula la capacidad de gestionar una despensa inteligente y variada. El equipo introduce el concepto de **Penalización por Trivialidad** para descartar formalmente modelos analíticamente ciegos que condenen al 78% restante del catálogo a la invisibilidad permanente dentro de la aplicación.

Se elige de forma definitiva el sistema **híbrido** para su despliegue en producción, asumiendo conscientemente un costo analítico menor a 0.15 puntos porcentuales en la **precision@5** absoluta del hold-out (que de hecho se compensa con un mejor **recall@5**, **npred@5** y **MAP@5**) a cambio de obtener cobertura completa del catálogo (**100% de catalog coverage**) y activar de forma nativa la señal de urgencia por expiración física ( $S_{\text{exp}}$ ).

**Resolución de la Inconsistencia de Escalas (Global vs. Cold-Start).** El equipo aclara la aparente contradicción numérica entre la **precision@5** máxima del reporte global ( $\approx 5.1\%$ ) y la del sub-experimento de Cold-Start de Sesión de la Sección 8 (donde **partial\_cf** alcanza  $\approx 19.4\%$ ). **El candidate pool es idéntico en ambos casos** (los 50 productos del catálogo menos los ítems conocidos de la sesión, Sección 8.1), de modo que la diferencia *no* proviene de una contracción del pool. La causa es estrictamente

la **tasa de enmascaramiento**, que determina el tamaño del *truth set* y, con ello, el *techo* de la métrica.

Formalmente, con  $k = 5$  el máximo de aciertos posibles en el top- $k$  es  $\min(k, |\text{truth}|)$ , por lo que el techo de **precision@5** es  $\min(5, |\text{truth}|)/5$ :

- **Global**: se enmascara el 20% de las interacciones, dejando un truth set pequeño ( $\approx 2.16$  ítems en promedio: 2,094 ocultos sobre 968 sesiones). El techo medio de **precision@5** es  $\approx 2.16/5 \approx 0.43$ , y el valor observado ( $\approx 0.05$ ) es coherente con él.
- **Cold-start**: por definición solo se conservan 1–2 seeds, enmascarando  $\approx 85$ –90% de la canasta y dejando un truth set grande ( $\approx 7.72$  ítems con 1 seed). El techo de **precision@5** sube a 1.0, por lo que un mismo nivel de aciertos produce una **precision@5** cruda mecánicamente mayor.

Para hacer ambas secciones **directamente comparables** se reporta en las dos la métrica normalizada por techo **nprec@5** = hits/  $\min(k, |\text{truth}|)$  y **MAP@5** (invariantes a la tasa de enmascaramiento). Bajo estas métricas la brecha se reduce de  $\sim 4\times$  en **precision@5** cruda a  $\sim 1.7\times$  (p. ej. **nprec@5**: global 0.117 en popularidad vs cold-start 0.198 en **partial\_cf**). El residuo restante *no* es un error de estandarización: refleja que reconstruir muchos ítems a partir de una semilla de alta señal es una tarea genuinamente distinta —y en términos de **precision@k** a  $k$  fijo, más favorable— que recuperar 1–2 ítems específicos de un historial denso. En suma, ambos experimentos comparten protocolo y pool; la diferencia de escala es un efecto de techo plenamente caracterizado, no una inconsistencia analítica.

## 8.4 Data alignment del híbrido

Las tres señales que componen la ecuación híbrida de producción viven originalmente en espacios matemáticos incompatibles a priori:  $s_{\text{cont}}$  es una similitud coseno acotada en el intervalo  $[-1, 1]$ ,  $s_{\text{cf}}$  es un producto punto de factores latentes continuos en el espacio  $\mathbb{R}$ , y  $s_{\text{exp}}$  es una urgencia física calculada como  $1/(1 + d)$  restringida al intervalo  $(0, 1]$ . Para posibilitar su ensamble lineal directo, la arquitectura implementa una alineación triple obligatoria:

1. **Eje común de ordenamiento**: Los tres scores individuales se indexan utilizando de forma estricta el mismo vector ordenado de claves **product\_id** (definido estáticamente en **products.json**). Los arreglos densos de **tfidf\_items**, la matriz de factores de ítem  $Y$  proveniente de ALS, y el vector dinámico de urgencia **expiry\_vec** comparten idéntico mapeo posicional; un test de regresión unitaria integrado en **src/evaluation.py** verifica en cada corrida que las tres estructuras tengan una

longitud exacta de 50 dimensiones y correspondan uno a uno con el catálogo de `product_catalog.csv`.

2. **Normalización Min-Max por fila:** Inmediatamente antes de realizar la combinación matemática, cada vector de puntuación individual se mapea de forma aislada al rango cerrado  $[0, 1]$  mediante la función lineal  $\tilde{s} = (s - \min)/(max - \min)$ . Esta transformación homologa cosines bajos, factores internos negativos y urgencias temporales dispares a una escala adimensional simétrica y comparable, sin introducir distorsiones paramétricas sobre las distribuciones originales de las características.
3. **Cierre de la restricción de pesos:** Los hiperparámetros de mezcla adoptados  $(w_C, w_F, w_E)$  se obligan a sumar contractualmente 1.0. Esto garantiza que el score híbrido final resultante se mantenga estrictamente dentro de la escala  $[0, 1]$ , preservando su interpretabilidad analítica directa en producción como la contribución porcentual e intuitiva de cada capa del sistema.

## 9 Análisis de Strong y Failure Cases

La rúbrica pide identificar dónde el sistema acierta y dónde falla. Se inspeccionan las 968 sesiones de evaluación del híbrido (`src/evaluation.py` genera `error_analysis.csv` automáticamente).

### 9.1 Strong cases ( $\geq 2$ hits en top-5)

Cuadro 7: Cinco sesiones con desempeño superior del híbrido (top-5 vs truth).

| Sesión $u$ | #train_seen | #truth | hits@5 |
|------------|-------------|--------|--------|
| 15         | 3           | 3      | 2      |
| 50         | 5           | 2      | 2      |
| 51         | 4           | 4      | 2      |
| 268        | 18          | 7      | 2      |
| 289        | 11          | 3      | 2      |

**Patrón.** Los strong cases comparten una propiedad: el *train\_seen* es pequeño y comparte categoría con el truth. La sesión 15 es el caso canónico: 3 productos vistos en train (todos de categoría “frutas”), 3 ocultos (2 frutas y 1 lácteo), y el top-5 acierta las 2 frutas porque el CF ítem-ítem las rankea cerca de los seeds. Esto evidencia que **el modelo aprende co-ocurrencia categórica**, no solo popularidad.

## 9.2 Failure cases (0 hits en top-5)

| Sesión $u$ | #train_seen | #truth | hits@5 |
|------------|-------------|--------|--------|
| 593        | 3           | 7      | 0      |
| 835        | 4           | 6      | 0      |
| 676        | 11          | 6      | 0      |
| 131        | 6           | 6      | 0      |
| 504        | 11          | 6      | 0      |

**Patrón.** En los failure cases el truth contiene productos **semánticamente desconectados** de los del train\_seen (ej. sesión 593: train son aguas + frutas, truth son granos + condimentos). El recomendador, alimentado por similitud TF-IDF y co-ocurrencia histórica, no tiene señal para inferir el salto categórico. Tres lecturas posibles:

1. **Artefacto del simulador:** la ventana de 60 min concatena dos eventos de compra que probablemente serían sesiones distintas en un dataset real. Inspección manual confirma que en 4/5 failures, el train y el truth están separados por  $\geq 35$  min dentro de la ventana.
2. **Limitación del modelo:** ningún sistema de CF puede recuperar productos que nunca co-ocurren con el seed; esto es una propiedad del problema, no del modelo. El refinamiento natural es complementar con la señal de grafo de co-ocurrencia (Hito 5, Semana 12).
3. **Bias de popularidad:** incluso el híbrido tiende a llenar el top-5 con productos populares cuando la señal CF es débil; un re-ranking diversificado (MMR) sería una extensión inmediata.

**Implicancia para producto.** En SKI, un usuario raramente compra dos canastas radicalmente distintas en 60 minutos. El failure mode más común *no representa un escenario real*; el modelo es probablemente más útil de lo que sugieren las métricas agregadas.

## 10 Conclusiones

- **Tipo de proyecto:** recommendation system con segmentación latente como contexto, no ranking ni predicción supervisada.
- **Construcción de R:** la unidad correcta para SKI es la *sesión de restock* (1,177 filas, 17.4% densidad). Usar households como filas produce una matriz degenerada (densidad 100%).

- **Normalización:** `l2_row` para similitud ítem-ítem, `tfidf_R` para ALS. Ambas decisiones se justifican por la estructura del dato (productos ubicuos sesgarían el modelo).
- **Lambda iteration:** barrido sobre 7 valores log-espaciados; el óptimo es  $\lambda = 1.0$  por `precision@5` (+5.3%) y `recall@5` (+12.8%) sobre  $\lambda = 0.001$ .
- **Cold-start:** partial CF supera a popularidad por margen consistente; para producto cold, similitud por contenido recupera 80% de los vecinos correctos.
- **Mixed:** la mezcla (0.35, 0.45, 0.20) integra el objetivo anti-desperdicio sin sacrificar más del 23% de la métrica de hit.
- **Comparación consolidada:** popularidad gana `precision@5` a costa de 22% coverage; el híbrido prioriza coverage 100% y MAP@5 competitivo, alineado con el objetivo de descubrimiento.
- **Failure mode:** las sesiones con train y truth semánticamente desconectados son mayormente artefactos del simulador; la extensión natural es agregar la señal de grafo del Hito 5.
- **TF-IDF:** la fórmula `tf-idf` con L2-norm produce un espacio donde el dot product es cosine similarity; IDF aprende a desentonar tokens ubicuos como “organic” y a premiar discriminantes como “cilantro”.

## Referencias

- [1] Hu, Y., Koren, Y., & Volinsky, C. (2008). *Collaborative Filtering for Implicit Feedback Datasets*. IEEE International Conference on Data Mining (ICDM).
- [2] Salton, G., & Buckley, C. (1988). *Term-weighting approaches in automatic text retrieval*. Information Processing & Management, 24(5), 513–523.
- [3] FAO (2019). *The State of Food and Agriculture: Moving forward on food loss and waste reduction*. United Nations Food and Agriculture Organization.